

ขั้นที่ 3 'PREPARE' (เตรียมข้อมูล) Data Cleaning ด้วย Google Sheets

Fundamentals of Data Science (พื้นฐานวิทยาการข้อมูล)

ผู้สอน: อาจารย์สุรัชย์ โทยสันติสุข | คณะการสร้างเจ้าของธุรกิจ มหาวิทยาลัยศรีปทุม

🧠 วงจร Data Science: เข้าสู่ขั้นที่ 3 'PREPARE'

บททวนความต่อเนื่องจาก COLLECT สู่ PREPARE เพื่อเตรียมพร้อมสู่ ANALYZE

STEP 1 ASK ตั้งคำถาม & สมมติฐาน (Session 1-2)	STEP 2 COLLECT ประเภทข้อมูล & Tidy Data (Session 3-4)	STEP 3 (วันนี้) PREPARE Data Cleaning ล้างข้อมูลให้ พร้อม (Session 5)	STEP 4 ANALYZE วิเคราะห์ด้วย AI Gemini (Session 6-7)	STEP 5 ACT Dashboard & ตัดสินใจธุรกิจ (Session 8-14)
--	--	--	---	---

✅ คาบที่แล้ว (Session 4)

- กฎเหล็ก 3 ข้อของ **Tidy Data** (Row = Observation, Col = Variable, Cell = Single Value)
- ออกแบบ Google Forms ลีอกประเภทคำถามและทำ Data Dictionary

★ คาบนี้ (Session 5)

- ข้อมูลจริงมี **Dirty Data** (พิมพ์ผิด ช่องว่างแฝง ข้อมูลซ้ำ ข้อมูลหลุดโลก)
- ใช้เครื่องมือ Google Sheets ทำความสะอาดข้อมูลให้คลีน 100% พร้อมบันทึก Cleaning Log

💀 กฎเหล็ก GIGO (Garbage In, Garbage Out): ข้อมูลสกปรก → วิเคราะห์เพี้ยน → AI ตอบมั่ว → ธุรกิจเจ๊ง!

4 เสาหลักการเรียนรู้ประจำคาบเรียน

≡ AGENDA

เส้นทางการเปลี่ยนข้อมูลดิบให้กลายเป็นทองคำทางธุรกิจที่สะอาดบริสุทธิ์

เสาหลักที่ 1



The Reality of Dirty Data

ทำไมข้อมูลจริงถึงสกปรก? ผลกระทบต่อผลกำไรและกฎ 80/20 ในโลก Data Science

เสาหลักที่ 2



5 Traps of Dirty Data

ฝ่า 5 กับดักตัวร้าย: ค่าซ้ำ ช่องว่าง ล่องหน ค่าว่าง วันที่สับสน และค่าหลุดโลก

เสาหลักที่ 3



Sheets Cleaning Toolkit

คลังอาวุธ Google Sheets: Data Cleanup, TRIM, PROPER, Find/Replace, Validation

เสาหลักที่ 4



Data Cleaning Log

กฎห้ามแตะ Raw Data และการทำ Audit Trail บันทึกประวัติเพื่อความยั่งยืน



เป้าหมายวันนี้: ทุกคนสามารถเปิดตารางยอดขายจริง ตรวจสอบจุดผิดพลาด และใช้เครื่องมือคลีนข้อมูลจนสะอาดได้ภายในเวลา 30 นาที

☢️ เสาหลักที่ 1: ความจริงอันโหดร้ายของ Dirty Data

⚠️ REALITY CHECK

ทำไมข้อมูลในโลกธุรกิจจริงถึงไม่เคยเรียบร้อยเหมือนในตำรา?

📊 กฎ 80/20 ของ Data Science

80%

เวลาของ Data Scientist และนักวิเคราะห์

หมดไปกับการ "**รวบรวม ตรวจสอบ และทำความสะอาดข้อมูล**"
(Cleaning & Wrangling) ส่วนเวลาในการสร้างโมเดลหรือ
วิเคราะห์จริงมีเพียง **20%** เท่านั้น

❓ ข้อมูลสกปรกมาจากไหน?

- **Human Error:** พนักงานพิมพ์ตกหล่น, เผลอกด Spacebar ถ้ายชื่อ, กรอกเบอร์โทรผิดรูปแบบ
- **Multiple Channels:** รวมข้อมูลจาก TikTok Shop, Shopee, หน้าร้าน POS แต่ละที่ตั้งชื่อสินค้าไม่เหมือนกัน
- **Copy-Paste Chaos:** คัดลอกข้อมูลจาก PDF หรือไลน์มาแปะใน Excel แล้วโครงสร้างพัง
- **System Glitch:** เบ็ตหลุดขณะส่งฟอร์มทำให้มีแถวซ้ำ หรือส่งข้อมูลไม่ครบ

💡 **Key Insight:** ธุรกิจที่สำเร็จไม่ได้มีข้อมูลเยอะที่สุด แต่คือธุรกิจที่ทำให้ข้อมูล **สะอาดและพร้อมใช้** เร็วที่สุด

ผลกระทบของข้อมูลสกปรกต่อทำไรธุรกิจ SME

 BUSINESS IMPACT

ต้นทุนที่มองไม่เห็นเมื่อตัดสินใจบนข้อมูลที่ไม่ได้ทำความสะอาด



สต็อกล้น / สต็อกขาด

ซื้อสินค้าสกะกดต่างกัน 2 แบบ ระบบคิดว่าเป็นคนละชิ้น ทำให้สั่งของมาดองจนเงินจม หรือสต็อกขาดจนเสียโอกาสขาย



ยิงแอดซ้ำ เสียค่าส่งฟรี

ข้อมูลลูกค้าซ้ำซ้อน ส่ง SMS หรือโปรโมชั่นซ้ำ หากลูกค้ารายเดิม 3 รอบ ทำให้ลูกค้ารำคาญและเปลี่ยนงบการตลาด



AI หลอน วิเคราะห์เพี้ยน

นำข้อมูลที่มีค่าผิดปกติ (เช่น ราคา -500 หรืออายุ 200 ปี) ป้อนให้ Gemini AI สรุปกลยุทธ์ ผลลัพธ์ที่ได้ย่อมผิดพลาดทันที



The 1-10-100 Rule: ป้องกันข้อมูลผิดเสีย **1 บาท** | คลีนข้อมูลก่อนวิเคราะห์เสีย **10 บาท** | แต่ถ้าปล่อยให้ข้อมูลผิดพลาดไปจนถึงมือลูกค้า ธุรกิจต้องจ่ายค่าเสียหาย **100 บาท!**

🛡️ เสาหลักที่ 2: ฝ่า 5 กายวิภาคข้อมูลสกปรก (5 Traps)

🔍 5 COMMON TRAPS

5 ปัญหาคลาสสิกที่พบในตารางยอดขายและฐานข้อมูลของธุรกิจไทย

Trap 1

📄 ข้อมูลซ้ำซ้อน (Duplicates)

ออเดอร์เดียวกันถูกบันทึก 2 ครั้ง ทำให้ยอดขาย
พอง ยอดสต็อกหาย

Trap 2

A ช่องว่างล่องหน & สะกดเพี้ยน

เปลอเคาะ Spacebar หน้า-หลัง หรือสะกดคนละ
แบบ Pivot รวมกลุ่มไม่ได้

Trap 3

💎 ข้อมูลขาดหาย (Missing Values)

ปล่อยเซลล์ว่าง, ค่า NULL, ใส่เครื่องหมายขีด (-)
โดยไม่แยกประเภท

Trap 4

📅 วันที่และตัวเลขสับสน (Inconsistent Format)

บันทึก ๖/๓/๒๕๖๖ สลับ ๓/๖/๒๕๖๖ หรือมีเครื่องหมายลูกน้ำ/ตัวอักษรปนจนสูตร SUM
ทำงานไม่ได้

Trap 5

⚡ ค่าผิดปกติ / ค่าหลุดโลก (Outliers)

ข้อมูลสุดโต่งที่เกิดจากพิมพ์ผิด เช่น อายุ 300 ปี, ราคาสินค้า -100 บาท ดึงค่า
เฉลี่ยเพี้ยน

➡ มาเจาะลึกอาการและวิธีรักษาของแต่ละ Trap ไปพร้อมกันทีละข้อ

Trap 1: ข้อมูลซ้ำซ้อน (Duplicate Records)

เมื่อแถวข้อมูลออเดอร์เดียวกันถูกบันทึกเป็น 2 แถวโดยไม่รู้ตัว

ตัวอย่างตารางที่มี Duplicate Rows

Order ID	ลูกค้า	สินค้า	ยอดเงิน
ORD-101	คุณสมศรี	เสื้อยืด Oversize	350
ORD-102	คุณวิชัย	กางเกงยีนส์ขากระบอก	890
ORD-102	คุณวิชัย	กางเกงยีนส์ขากระบอก	890
ORD-103	คุณกานดา	กระเป๋าผ้าแคนวาส	290

! สาเหตุและผลกระทบ:

- ลูกค้ากดยืนยันออเดอร์ 2 ครั้งตอนเน็ตกระตุก
- แอดมินดึงไฟล์ยอดขายจาก Shopee มาต่อกับ TikTok แล้วมีรายการทับซ้อน
- ผลเสีย:** ยอดขายรวมพองเกินจริง 890 บาท คิดว่าขายดีแต่เงินในบัญชีจริงไม่ตรง!

✓ วิธีสังเกต:

ตรวจสอบคอลัมน์ที่เป็น **Primary Key / Unique ID** (เช่น Order ID, รหัสลูกค้า) หากมีค่าซ้ำกันในคอลัมน์นี้ แสดงว่ามี Duplicate เกิดขึ้น

หลักคิด: ก่อนรวมยอดขายทุกครั้ง ต้องตรวจสอบและลบแถวซ้ำออกเสมอ



ทางแก้ Trap 1: เมนู Data Cleanup → Remove Duplicates

TOOL GUIDE

วิธีลบแถวซ้ำอย่างปลอดภัยด้วยฟังก์ชันสำเร็จรูปใน Google Sheets

▶ 3 ขั้นตอนง่ายๆ ลบข้อมูลซ้ำ

1. คลุมแถบข้อมูลทั้งหมด (หรือกด Ctrl + A)
2. ไปที่เมนูบาร์ด้านบน:
Data (ข้อมูล) → Data cleanup → Remove duplicates
3. ตีถูกที่ช่อง **"Data has header row"** (ข้อมูลมีแถวส่วนหัว)
4. เลือกว่าจะเช็คซ้ำทุกคอลัมน์ หรือเช็คเฉพาะคอลัมน์ Order ID แล้วกด **Remove duplicates**

🎯 ข้อควรระวังในการเลือกคอลัมน์!

- ถ้าติ๊ก **"Select all columns"**: ระบบจะลบก็ต่อเมื่อ *ทุกช่องในแถว* นั้นเหมือนกันทุกตัวอักษร
- ถ้าติ๊กเฉพาะ **"Order ID"**: หากเจอ Order ID ซ้ำ ระบบจะเก็บแถวแรกไว้ และลบแถวที่สองทันที



คำเตือน: หากมี 1 ออเดอร์ซื้อสินค้าหลายชิ้น อย่าติ๊กเฉพาะ Order ID เพราะจะลบสินค้าชิ้นอื่นทิ้ง!



Alternative Formula: สามารถใช้สูตร **=UNIQUE(A2:D100)** เพื่อดึงเฉพาะแถวที่ไม่ซ้ำไปวางในชีตใหม่ได้โดยไม่กระทบข้อมูลต้นฉบับ

ปัญหาคลาสสิกที่ตามองไม่เห็น แต่ทำให้สูตรคำนวณและ Pivot Table พังทลาย

 **ดูเผินๆ เหมือนกัน แต่ระบบมองว่าต่างกัน!**

ข้อความที่พิมพ์	สิ่งที่สายตามนุษย์เห็น	สิ่งที่คอมพิวเตอร์เห็น
"ชบา"	ชบา	ความยาว 3 ตัวอักษร
" ชบา"	ชบา	มี Space ข้างหน้า (4 ตัว)
"ชบา "	ชบา	มี Space ข้างหลัง (4 ตัว)
"ช บา"	ช บา	Space ตรงกลาง 2 เคาะ

 หายนะที่เกิดขึ้นกับธุรกิจ:

- **Pivot Table แยกแถว:** สรุปยอดขายเสื้อ "ชบา" กลายเป็น 3 บรรทัด ยอดขายกระจายรวมยอดไม่ติด!
- **VLOOKUP ขึ้น #N/A:** ค้นหารหัสสินค้าไม่เจอ เพราะรหัสในตารางมีเคาะเว้นวรรคแอบแฝง
- **Filter หลุด:** กรองหาสาขา "สยาม" ไม่เจอสาขาที่มีช่องว่างข้างหน้า



การตรวจจับ: ใช้สูตร =LEN(A2) เพื่อดูความยาวตัวอักษรจริงว่าเกินกว่าที่ควรจะเป็นหรือไม่

กฎทอง: 1 เคาะของมนุษย์ คือ 1 รหัสลับของคอมพิวเตอร์เสมอ

✂️ ทางแก้ Trap 2: ฟังก์ชัน TRIM & เครื่องมือ Trim Whitespace

ตัดช่องว่างส่วนเกินออกอย่างหมดจดใน 1 วินาที

🔧 วิธีที่ 1: เมนูอัตโนมัติ (Data Cleanup)

- 1. คลุมคอลัมน์ที่มีปัญหา (เช่น คอลัมน์ชื่อสินค้า)
- 2. ไปที่ **Data** → **Data cleanup** → **Trim whitespace**
- 3. ระบบจะตัดช่องว่างที่อยู่ **ข้างหน้าสุด** และ **ข้างหลังสุด** ของทุกเซลล์ทิ้งทันที

⚡ **รวดเร็ว สะดวก ไม่ต้องเขียนสูตร**

</> วิธีที่ 2: ฟังก์ชัน =TRIM()

ใช้สร้างคอลัมน์ใหม่เพื่อความสะอาดสมบูรณ์แบบ:

=TRIM(A2)

คุณสมบัติของ =TRIM():

นอกจากตัดช่องว่างหน้า-หลังแล้ว ยัง **ยุบช่องว่างตรงกลางที่เคาะเกิน 1 ครั้ง** ให้เหลือเพียง 1 เคาะมาตรฐานโดยอัตโนมัติ!

ก่อน TRIM: " เสื้อยืด สีขาว " (ความยาว 19 ตัวอักษร)

หลัง TRIM: "เสื้อยืด สีขาว" (เหลือช่องว่าง 1 เคาะตรงกลางสะอาด 100%)

AB

Trap 2 (ต่อยอด): ตัวสะกดเพี้ยน & ตัวพิมพ์เล็ก/ใหญ่

T↑ INCONSISTENT TEXT

ความไม่สม่ำเสมอของข้อความที่ทำให้ฐานข้อมูลแตกกระจาย

× ปัญหาที่พบในร้านค้าออนไลน์

หมวดหมู่	สิ่งที่พนักงานกรอกมา	ผลกระทบ
ไซส์เสื้อ	"XL", "x1", "X1", " เอ็กแอล"	ระบบนับเป็น 4 ไซส์!
สีสินค้า	"ขาว", "White", "ขาวออฟไวท์"	รวมยอดขายสีขาวไม่ได้
ชื่อสาขา	"สยาม", "Siam", "สาขาสยาม"	เทียบยอดสาขาลำบาก

หลักปฏิบัติ: ข้อมูลประเภทเดียวกัน ต้องสะกดเหมือนกันและใช้รูปแบบเดียวกันทั้งตาราง

⚠️ ทำไมถึงเป็นปัญหาใหญ่?

คอมพิวเตอร์และระบบฐานข้อมูลไม่ได้มี "Common Sense" เหมือนมนุษย์ เมื่อตัวอักษรต่างกันแม้แต่ตัวเดียว หรือตัวพิมพ์เล็กต่างกับตัวพิมพ์ใหญ่ ระบบจะแยกเป็นคนละประเภททันที

🎯 มาตรฐานสากล: ต้องเลือกใช้ คำมาตรฐานคำเดียว (Standard Canonical Term) สำหรับค่าข้อมูลแต่ละความหมาย



ทางแก้ Text Formatting: ฟังก์ชันจัดฟอนต์ & Find & Replace

TEXT TOOLS

ปรับตัวพิมพ์ให้เท่ากัน และแก้คำสะกดผิดเป็นหมื่นแหวในคลิกเดียว

A ฟังก์ชันปรับขนาดตัวพิมพ์สากล

- **=UPPER(A2)** : เปลี่ยนเป็นตัวพิมพ์ใหญ่ทั้งหมด เช่น x1 → XL
- **=LOWER(A2)** : เปลี่ยนเป็นตัวพิมพ์เล็กทั้งหมด เช่น Gmail.COM → gmail.com
- **=PROPER(A2)** : ตัวพิมพ์ใหญ่นำหน้าคำ เช่น bangkok → Bangkok

🔍 Find & Replace ขั้นเทพ (Ctrl + H)

ใช้แก้คำสะกดผิดหรือเปลี่ยนชื่อเรียกเป็นกลุ่ม:

1. กด Ctrl + H (หรือเมนู **Edit** → **Find and replace**)
2. ช่อง **Find**: พิมพ์คำที่สะกดผิด (เช่น White)
3. ช่อง **Replace with**: พิมพ์คำมาตรฐาน (เช่น ชาว)
4. ติ๊กถูกที่ **"Match entire cell contents"** เพื่อป้องกันแทนที่ผิดคำ!



Pro Tip: ติ๊ก **"Match entire cell contents"** เสมอ! มิฉะนั้นหากค้นหาคำว่า "ขา" เพื่อแก้เป็น "ขาว" คำว่า "กางเกงขายาว" จะกลายเป็น "กางเกงขาวยาว" กันที!

Trap 3: ข้อมูลขาดหาย (Missing Values / Null Data)

? TRAP 3

หลุมดำของตารางข้อมูล: เซลล์ว่าง, ค่า Null, และการกรอกเครื่องหมายกำกับ

× ลักษณะของ Missing Data

รหัสลูกค้า	ชื่อลูกค้า	เบอร์โทร	ยอดซื้อสะสม
CUST-001	คุณสมศักดิ์	0812345678	4,500
CUST-002	คุณพรทิพย์	(ช่องว่าง)	1,200
CUST-003	คุณประเสริฐ	-	NULL
CUST-004	คุณดาริกา	0899998888	0

⚠ ความกำกวมของ Missing Data:

- ช่องว่าง vs เลข 0: ยอดซื้อสะสมเป็น "ช่องว่าง" หมายถึงยังไม่เคยซื้อ หรือระบบลืมนับก็ก? ไม่เหมือนกับชื่อ "0 บาท"!
- ใส่ขีด (-): ทำให้คอลัมน์ตัวเลขกลายเป็นข้อความ สูตร AVERAGE หรือ SUM พังทันที

🔍 สูตรตรวจจับเซลล์ว่าง

- `=ISBLANK(A2)` : ส่งค่า TRUE ถ้าเซลล์นั้นว่างเปล่า
- `=COUNTBLANK(A2:A100)` : นับจำนวนเซลล์ว่างทั้งหมดในคอลัมน์

ข้อคิดเตือนใจ: "ไม่มีข้อมูล" ไม่เท่ากับ "ข้อมูลเป็นศูนย์" ต้องแยกแยะให้ชัดเจน



ทางแก้ Trap 3: กลยุทธ์การรับมือ Missing Data สำหรับธุรกิจ

MISSING STRATEGIES

เมื่อเจอช่องว่าง ควร "ลบทิ้ง" หรือ "เติมค่า" ให้เหมาะสมกับบริบท?

ทางเลือกที่ 1

🗑️ ลบแถวทิ้ง (Deletion)

ใช้เมื่อ: แถวนั้นขาดคอลัมน์สำคัญมากจนนำไปใช้ประโยชน์ไม่ได้ และมีสัดส่วนน้อย (< 5% ของข้อมูลทั้งหมด)

ตัวอย่าง: ขาดทั้งชื่อลูกค้า เบอร์โทร และยอดเงิน หรือไม่มียอดขายบันทึกไว้เลย → *ลบแถวทิ้งได้เลย*

ทางเลือกที่ 2

🔄 เติมค่าทดแทน (Imputation)

ใช้เมื่อ: ไม่ต้องการเสียแถวข้อมูลไป โดยแทนค่าด้วยค่ามาตรฐานที่สมเหตุสมผล

- ข้อความ: แทนด้วยคำว่า "ไม่ระบุ" หรือ "Unknown"
- ตัวเลข: แทนด้วยค่ามัธยฐาน (Median) หรือค่าเฉลี่ย (Mean) ของกลุ่ม



กฎเหล็กทางธุรกิจ: ห้ามแอบลบหรือเติมค่าตามใจชอบโดยไม่บันทึก! ทุกการลบแถวหรือแทนค่า ต้องจดลงใน **Data Cleaning Log** เสมอ



Trap 4: ความโกลาหลของวันที่และตัวเลข (Format Chaos)

TRAP 4

ปัญหาเรื่องระบบคิดว่าเป็นตัวหนังสือ (Text) ทำให้บวกเลขไม่ได้ เรียงลำดับไม่ไป

❌ ปัญหาวันที่และตัวเลขที่พบบ่อย

ค่าที่บันทึกมา	สิ่งที่ระบบตีความ	ปัญหาที่เกิด
05/03/2026	5 มี.ค. หรือ 3 พ.ค.?	ว/ด/ป สลับกับ ด/ว/ป สรุปลยอดราย เดือนผิดทันที
2569/03/01	ปี พ.ศ. ผสม ค.ศ.	ระบบจัดเป็นข้อความ เรียงตาม Timeline ไม่ได้
"฿ 1,250"	ข้อความ (Text)	สูตร SUM ข้ามเซลล์นี้ ยอดรวม กลายเป็น 0!

🔍 เทคนิคตรวจสอบด้วยสายตา (Alignment Rule):

- ใน Google Sheets: ตัวเลขและวันที่แท้จริง จะชิดขวา (Align Right) เสมอโดยธรรมชาติ
- หากเห็นตัวเลขหรือวันที่ ชิดซ้าย (Align Left) แสดงว่าระบบมองเป็น "ข้อความ" (Text) ไม่สามารถนำไปคำนวณได้!

✏️ สูตรแปลง Text เป็นตัวเลข

ใช้ฟังก์ชัน `=VALUE(SUBSTITUTE(A2, "฿", ""))` เพื่อตัดสัญลักษณ์เงินออกและแปลงเป็นตัวเลขคำนวณได้

ข้อแนะนำ: ตั้ง Format วันที่ในชีตให้เป็น **YYYY-MM-DD (ISO 8601)** เพื่อความเป็นสากล



ทางแก้ Trap 4: ปรับ Format ตัวเลขและวันที่ให้เป็นมาตรฐาน

🛠️ FORMATTING TOOLS

เครื่องมือ Format Menu และ Text-to-Columns เพื่อแปลงข้อมูลให้คำนวณได้

📊 การจัด Format ตัวเลขให้ถูกต้อง

- เลือกคอลัมน์ราคาสินค้าหรือยอดเงิน
- ไปที่เมนู **Format** → **Number** → **Number (1,000.12)** หรือ **Currency**
- ข้อควรระวัง: การใส่ลูกน้ำและสัญลักษณ์เงินควรทำผ่าน Format Menu เท่านั้น ห้ามพิมพ์สัญลักษณ์เข้าไปในเซลล์เอง เพราะจะกลายเป็น Text

📅 การจัดระเบียบวันที่ (Date Normalization)

- เลือกคอลัมน์วันที่ → **Format** → **Number** → **Date**
- หากวันที่มาจากต่างประเทศแล้วระบบอ่านสลับ ด/ว/ป ให้ใช้เมนู: **File** → **Settings** → **Locale** ตั้งค่าภาษาให้ตรงกับแหล่งที่มา
- ฟังก์ชันสร้างวันที่มาตรฐาน: **=DATE(ปี, เดือน, วัน)**



สูตรแปลง Text วันที่เพี้ยน: หากระบบดึงวันที่มาเป็น 20260315 สามารถใช้สูตร **=DATE(LEFT(A2,4), MID(A2,5,2), RIGHT(A2,2))** แปลงเป็นวันที่แท้จริงได้ทันที

Trap 5: ค่าผิดปกติ / ค่าหลุดโลก (Outliers & Anomalies)

⚠ TRAP 5

ตัวเลขสุดโต่งที่เกิดจากพิมพ์ผิดหรือระบบล่ม ซึ่งจะลากค่าเฉลี่ยจนบิดเบือนทั้งธุรกิจ

🔴 ตัวอย่าง Outlier ทำลายค่าเฉลี่ย

ลูกค้า	สินค้า	จำนวน (ชิ้น)	ยอดซื้อ (บาท)
ลูกค้า A	สลัดอกไก่	1	120
ลูกค้า B	ข้าวยำแซลมอน	2	380
ลูกค้า C	น้ำผลไม้สกัด	999 (เพลอปิมพ์เบิ้ล)	-500 (ราคาติดลบ)
ลูกค้า D	สเต็กเต้าหู้	1	150

📉 อนุภาพทำลายล้างของ Outlier:

- ค่าเฉลี่ยยอดซื้อจริงควรอยู่ที่ประมาณ **216 บาท/ออเดอร์**
- แต่เมื่อมีออเดอร์หลุดโลกหลุดเข้ามา ค่าเฉลี่ยจะกลายเป็น **37.5 บาท** และยอดขึ้นเฉลี่ยกลายเป็น **250 ชิ้น!**
- ผลเสีย:** ฝ่ายจัดซื้อเตรียมสต็อกไก่เพิ่ม 1,000 ชิ้นจนเน่าทิ้งเพราะดูยอดเฉลี่ยที่เพี้ยน!

❓ **สถิติเบื้องต้น:** เมื่อข้อมูลมี Outlier ให้ใช้ **Median (มัธยฐาน)** แทน **Mean (ค่าเฉลี่ย)** เพราะทนทานต่อค่าหลุดโลกมากกว่า

หลักคิด: ก่อนสรุปตัวเลขรายงานผู้บริหาร ต้องสแกนหาค่า Min และ Max เสมอ

ทางแก้ Trap 5: การตรวจจับและจัดการ Outliers

+ DETECTION METHODS

วิธีค้นหาค่าหลุดโลกด้วย Sort, Filter และการตัดสินใจเชิงธุรกิจ

วิธีที่ 1

↓ Sort เรียงลำดับ Min / Max

คลิกขวาที่คอลัมน์ตัวเลข → **Sort A → Z** (ดูค่าน้อยสุด) และ **Sort Z → A** (ดูค่ามากที่สุด) จะเห็นค่าติดลบหรือตัวเลขมหาศาลโผล่ขึ้นมาทันที

วิธีที่ 2

▼ สร้าง Filter คัดกรองช่วงตัวเลข

เปิด Filter (Ctrl + Shift + L) → Filter by condition → **Less than 0** (หายอดติดลบ) หรือ **Greater than 10,000** เพื่อตรวจสอบความผิดปกติ

วิธีที่ 3

✍ การตัดสินใจเชิงธุรกิจ

ถ้าเป็นข้อผิดพลาดชัดเจน (เช่น อายุ 300 ปี) ให้แก้หรือลบทิ้ง แต่ถ้าเป็นลูกค้ารายใหญ่ซื้อจริง (VIP) ให้ **แยกวิเคราะห์ต่างหาก** ไม่รวมกับลูกค้ารายย่อย



จำไว้ว่า: Outlier บางตัวไม่ใช่ข้อผิดพลาด แต่เป็น **สัญญาณทางธุรกิจ (Business Insight)** เช่น พฤติกรรมการโกง (Fraud) หรือลูกค้าองค์กรสั่งซื้อล็อตใหญ่



เทคนิคส่งข้อมูลผิดด้วยสี: Conditional Formatting

VISUAL AUDIT

เปลี่ยนเซลล์ที่มีปัญหาให้เรืองแสงอัตโนมัติ เพื่อตรวจสอบได้ด้วยสายตาใน 3 วินาที

วิธีเปิดใช้งาน Conditional Formatting

1. เลือกพื้นที่ข้อมูลที่ต้องการส่ง (เช่น คอลัมน์ยอดขายหรือเบอร์โทร)
2. ไปที่เมนู **Format** → **Conditional formatting**
3. หน้าต่างขวามือจะปรากฏกฎให้เลือก (Format rules)
4. เลือกเงื่อนไขและเลือกสีไฮไลต์ (แนะนำสีแดงอ่อนสำหรับจุดผิดปกติ)

3 กฎคลาสสิกที่เจ้าของธุรกิจต้องตั้งไว้เสมอ

- **จับเซลล์ว่าง:** เลือก *"Is empty"* → สั่งให้มุมสีแดงอ่อน (เตือนว่ามี Missing Data)
- **จับยอดติดลบ/ผิดปกติ:** เลือก *"Less than 0"* → สั่งให้ตัวหนังสือสีแดงหนา
- **จับห้ำหซ้ำ (Duplicates):** ใช้สูตรเฉพาะ (Custom formula is):

```
=COUNTIF(A:A, A1) > 1
```

✔ **ประโยชน์สูงสุด:** เมื่อมีข้อมูลใหม่อัปเดตเข้ามา เซลล์ไหนมีปัญหาก็ติดไฟแดงทันที ไม่ต้องมานั่งเพ่งทีละบรรทัด!



เกราะป้องกันก่อนข้อมูลพัง: Data Validation ใน Sheets



PREVENTIVE DEFENSE

ป้องกันข้อมูลสกปรกตั้งแต่วาง "Quality at the Source" ล็อกไม่ให้พนักงานกรอกมั่ว

ประเภทที่ 1

📄 ดรอปลาว์ด (Dropdown)

บังคับให้เลือกจากรายการ เช่น ไซส์ S, M, L, XL หรือสถานะ รอชำระ, ส่งแล้ว, ยกเลิก
ป้องกันปัญหาพิมพ์ตกและเคาะจรัส 100%

ประเภทที่ 2

🔢 ล็อกช่วงตัวเลข (Number Range)

กำหนดว่าจำนวนสินค้าต้อง greater than 0
และราคาสินค้าต้อง between 10 and 50000
ป้องกันการใส่ราคาติดลบหรือพิมพ์ 99999

ประเภทที่ 3

📅 บังคับรูปแบบวันที่ (Valid Date)

เลือกเงื่อนไข is valid date ทำให้ผู้กรอก
สามารถดับเบิลคลิกเลือกวันจากปฏิทิน (Date
Picker) ได้ทันที ปัญหาวันที่ผิดรูปแบบจะหมดไป



ข้อแนะนำการตั้งค่า: ในส่วน "If the data is invalid" ให้เลือกติ๊กที่ "Reject input" (ปฏิเสธข้อมูล) เพื่อไม่ให้บันทึกค่าผิดพลาดลงชีตได้
เด็ดขาด!



เสาหลักที่ 4: กฎเหล็ก "ห้ามแตะต้อง Raw Data เด็ดขาด!"

🚫 GOLDEN RULE

กฎแห่งความอยู่รอดของคนทำงานกับข้อมูล: Don't Touch the Raw Data!

❌ สิ่งที่มีมือสมัครเล่นชอบทำ (ห้ามทำเด็ดขาด!)

- เปิดไฟล์ยอดขายดิบที่โหลดมาจากระบบ แล้วกดลบแถว ลบช่อง แก้ตัวเลขกับลงไปทันที
- เมื่อเวลาผ่านไป สรุปตัวเลขผิดพลาด หรือเกิดข้อสงสัย **ไม่สามารถตรวจสอบย้อนกลับได้เลยว่าข้อมูลเดิมคืออะไร** เพราะไฟล์เดิมถูกทำลายไปแล้ว!

✅ สิ่งที่มีอาชีพทำเสมอ (Best Practice)

- **ขั้นตอนที่ 1:** ล็อกซิตต้นฉบับ ตั้งชื่อว่า raw_data_backup และตั้งสิทธิ์เป็น View Only
- **ขั้นตอนที่ 2:** Duplicate (ทำสำเนา) ออกมาเป็นซิตใหม่ชื่อ cleaned_data แล้วลงมือคลีนในซิตนี้เท่านั้น
- **ขั้นตอนที่ 3:** บันทึกทุกขั้นตอนลงใน **Data Cleaning Log**



หากทำข้อมูลดิบเสียหาย คุณจะไม่มีหลักฐานยืนยันยอดขายย้อนหลัง และไม่สามารถรับข้อมูลใหม่ได้อีกตลอดกาล!

🕒 Data Cleaning Log: สมุดบันทึกประวัติการชำระข้อมูล

ทำไมธุรกิจเจ้าของกิจการต้องมี Audit Trail ทุกครั้งที่ทำความสะอาดข้อมูล?



ทำซ้ำได้ (Reproducibility)

เมื่อสิ้นเดือนมีไฟล์ยอดขายเดือนใหม่เข้ามา เราสามารถดู Log แล้วทำตามขั้นตอนเดิมได้ทันที ไม่ต้องมานั่งคิดใหม่แต่ต้น



ส่งต่องานในทีมได้

เมื่อเจ้าของธุรกิจส่งต่อให้แอดมินหรือจ้าง Data Analyst มาช่วยงาน ทุกคนจะรู้กันที่ว่าข้อมูลผ่านการปรับแต่งอะไรมาบ้าง



ตรวจสอบย้อนหลังได้ (Audit)

หากตัวเลขทางบัญชีไม่ตรง สามารถเปิดดูได้ทันทีว่าทำไมถึงลบ 3 แถวนั้นทิ้ง ลบเมื่อไหร่ และใครเป็นคนตัดสินใจ

“If you didn't log it, it didn't happen — and if it broke, you won't know why.” (ถ้าไม่จด Log ถือว่าไม่ได้ทำ และถ้าข้อมูลพัง คุณจะไม่รู้เลยว่าพังเพราะอะไร)

 6 องค์ประกอบมาตรฐานของ Data Cleaning Log

 STANDARD FORMAT

โครงสร้างตารางบันทึกการทำความสะอาดข้อมูลที่นักศึกษาต้องทำใน Workshop

องค์ประกอบ	ความหมาย & รายละเอียด	ตัวอย่างการบันทึกจริง
1. Timestamp	วันและเวลาที่ดำเนินการ	2026-09-23 10:15 น.
2. Column Name	คอลัมน์ที่มีปัญหาและทำการแก้ไข	Column C (ชื่อสินค้า), Column E (ราคา)
3. Issue Found	ปัญหาที่ตรวจพบ (ระบุให้ชัดเจน)	มีช่องว่างแฝงหน้า-หลัง และชื่อสะกด "XL" ปน "x1"
4. Action / Tool	วิธีแก้ไข หรือสูตร/เครื่องมือที่ใช้	ใช้ฟังก์ชัน TRIM() และเปลี่ยนเป็น =UPPER()
5. Rows Affected	จำนวนแถวที่ได้รับผลกระทบจากการแก้ไข	18 แถว (จากทั้งหมด 120 แถว)
6. Operator	ชื่อผู้ดำเนินการและเหตุผล	สมชาย (แอดมินร้าน) – ปรับให้เป็นมาตรฐานเดียวกัน

 Data Cleaning Log มักถูกสร้างไว้เป็น Sheet แผ่นที่ 2 ถัดจากตารางข้อมูลหลักใน Google Sheets

ตัวอย่างจริง: หน้าตาตาราง Data Cleaning Log

TEMPLATE EXAMPLE

เกมเพลตฟอร์มมาตรฐานสำหรับนำไปประยุกต์ใช้กับธุรกิจจริงได้ทันที

#	Timestamp	คอลัมน์	ปัญหาที่พบ	เครื่องมือ / วิธีแก้ไข	จำนวนแถว	ผู้ดำเนินการ
1	23/09/2026 10:00	ทุกคอลัมน์	มีออเดอร์ซ้ำจากระบบ TikTok	Data → Remove Duplicates (เช็ค Order ID)	ลบ 4 แถว	สมชาย
2	23/09/2026 10:05	ชื่อสินค้า	มีช่องว่างแฝงท้ายชื่อเมนู	Data → Trim whitespace	แก้ 12 แถว	สมชาย
3	23/09/2026 10:12	สีสินค้า	พิมพ์ "White" ปนกับ "ขาว"	Ctrl + H แทนที่ "White" ด้วย "ขาว"	แก้ 7 แถว	กานดา
4	23/09/2026 10:20	ราคาสินค้า	เซลล์ว่าง (Missing Value)	เติมราคามาตรฐานตามแคตตาล็อกสินค้า	แก้ 2 แถว	กานดา
5	23/09/2026 10:28	จำนวนชิ้น	พิมพ์ 999 ชิ้น (Outlier เกินจริง)	เช็กสลิปจริง แก้เป็น 1 ชิ้น	แก้ 1 แถว	สมชาย



สังเกตได้ว่า: เมื่อมี Log ชัดเจนแบบนี้ หากผู้บริหารหรืออาจารย์มาตรวจงาน จะทราบทันทีว่าข้อมูลมีความน่าเชื่อถือและผ่านกระบวนการตรวจสอบที่รัดกุม 100%

กรณีศึกษา 1: ชบา โคลตติ้ง (Chaba Clothing)

ร้านเสื้อผ้าแฟชั่น Multi-channel ที่ยอดสต็อกไม่ตรงเพราะปัญหา Text และ Duplicate

ปัญหาที่ร้านชบาเจอ

- ดึงออเดอร์จาก TikTok Shop และ LINE OA มารวมกันใน Sheets:
- ไซส์เสื้อบันทึกปนกันมั่ว: "s", "S", "small", "เอส"
 - สีเสื้อมีทั้ง "ขาว", "white", " ขาว "
 - ลูกค้ายืนยันออเดอร์ใน TikTok 2 ครั้งตอนเน็ตค้าง ทำให้ออเดอร์เบิ้ล
 - **ผลกระทบ:** สต็อกยอดขายเสื้อไซส์ S ได้ไม่ครบ สต็อกจริงล้นโกดังแต่ในระบบขึ้นว่าหมด!

ปฏิบัติการคลีนข้อมูลของร้านชบา

1. **Remove Duplicates:** กรอง Order ID ซ้ำ ตัดออเดอร์เบิ้ลออก 6 ออเดอร์
2. **Trim Whitespace:** ตัดช่องว่างหน้า-หลังคอลัมน์สีและไซส์
3. **Standardize Text:** ใช้สูตร =UPPER(TRIM(A2)) ปรับไซส์เป็น S, M, L, XL ทั้งหมด
4. **Find & Replace:** เปลี่ยนคำว่า "White" เป็น "ขาว"
5. **Data Validation:** สร้างดรอปดาวน์ให้แอดมินเลือกไซส์ ห้ามพิมพ์มือเอง

 **ผลลัพธ์:** สต็อกตรงกับของจริง 100% สต็อกยอดขายต่อสัปดาห์ได้ใน 1 คลิก ไม่เสียโอกาสขายอีกต่อไป

🍴 กรณีศึกษา 2: เฮลตี้ไบท์ส (HealthyBites Delivery)

ธุรกิจอาหารเพื่อสุขภาพเดลิเวอรี่ ที่ Pivot Table พังเพราะช่องว่างแฝงท้ายชื่อเมนู

❌ ปัญหาที่เฮลตี้ไบท์สเจอ

- เจ้าของร้านต้องการสรุป "เมนูขายดีประจำสัปดาห์" ด้วย Pivot Table:
- เมนู "ข้าวต้มไก่ย่าง" มีพนักงานเผลอกด Spacebar แฝงไว้ข้างหลัง "ข้าวต้มไก่ย่าง "
 - Pivot Table จึงแยกเป็น 2 บรรทัด คนละเมนู ยอดขายตกไปอยู่อันดับ 5
 - ราคาสินค้าบางรายการปล่อยว่างไว้ เพราะเป็นเมนูใหม่แอดมินยังไม่ได้ใส่ราคา
 - **ผลกระทบ:** เจ้าของร้านเข้าใจผิดว่าข้าวต้มไก่ขายไม่ดี เกือบตัดสินใจตัดเมนูนี้ออกจากร้าน!

🔧 ปฏิบัติการคลีนข้อมูลกู้ชีพเมนูเด็ด

1. **Trim Whitespace:** สั่งตัดช่องว่างคอลัมน์ชื่อเมนูทั้งหมดทันที
2. **Conditional Formatting:** ไฮไลต์เซลล์ว่างในคอลัมน์ราคา พบราคาว่าง 3 จุด
3. **Missing Imputation:** นำราคาจาก Master Menu มาเติมให้ครบ
4. **Refresh Pivot Table:** รวมยอดขายเมนูข้าวต้มไก่ได้ถูกต้อง กลับขึ้นมาเป็นอันดับ 1 ของร้านทันที!

💡 **บทเรียน:** แค่ช่องว่าง 1 เคาะ เกือบทำให้ร้านอาหารสูญเสียเมนู Signature ที่สร้างกำไรสูงสุด

🏋️‍♂️ กรณีศึกษา 3: ยิมฟิต เอ็กซ์เพรส (GymFit Express)

💪 FITNESS CASE

ฟิตเนสรายเดือนและ PT สตูดิโอ กับปัญหาวันที่สับสนและค่าผิดปกติอายุ 300 ปี

🚩 ปัญหาระบบสมาชิกของ GymFit

- พนักงานกรอกวันเริ่มสมาชิกสลับกัน: บางคนกรอก ว/ด/ป (12/05/2026) บางคนกรอก ด/ว/ป (05/12/2026)
- ระบบส่งแจ้งเตือนต่ออายุสมาชิกมั่ว ลูกค้าเพิ่งสมัครเมื่อวานแต่ได้รับ SMS ว่าหมดอายุแล้ว!
- ช่องอายุกรอกเลข 300 ปี เพราะแป้นพิมพ์ค้าง ทำให้ค่าเฉลี่ยอายุสมาชิกของฟิตเนสกลายเป็น 68 ปี ทั้งที่เป็นกลุ่มวัยรุ่น

🛡️ การแก้ไขและวางระบบมาตรฐาน

- Date Parsing:** ใช้ Text-to-Columns และสูตร DATE() จัดรูปแบบวันหมดอายุเป็น YYYY-MM-DD ทั้งระบบ
- Outlier Filter:** กรองคอลัมน์อายุ พบค่า 300 ปี แก้ไขเป็น 30 ปีตามบัตรประชาชน
- Data Validation:** ล็อกช่วงอายุต้องอยู่ระหว่าง 15 ถึง 85 ปี และบังคับให้เลือกวันที่ผ่าน Date Picker เท่านั้น

😊 **ผลลัพธ์:** ระบบแจ้งเตือนต่ออายุสมาชิกทำงานแม่นยำ อัตราการต่อสัญญาสมาชิกเพิ่มขึ้น 25%

สรุป 5 ขั้นตอนปฏิบัติการ Data Cleaning มืออาชีพ

✓ STANDARD SOP

Workflow ที่นักศึกษาทุกคนต้องทำตามตั้งแต่ต้นจนจบก่อนนำข้อมูลไปวิเคราะห์

STEP 1 Backup Raw Data Duplicate ชีตต้นฉบับ ห้ามแตะต้องไฟล์ดิบ	STEP 2 Audit & Detect ใช้ Conditional Format และ Filter ส่องจุดผิด	STEP 3 Clean Structure ลบ Duplicate, Trim Whitespace, ปรับตัวพิมพ์	STEP 4 Handle Values จัดการ Missing Data และตัด/แก้ Outliers	STEP 5 Document Log บันทึกทุกขั้นตอนลง Data Cleaning Log
--	--	--	--	--


🔗 พร้อมแล้วสำหรับขั้นต่อไป: ANALYZE With AI!

เมื่อข้อมูลผ่านกระบวนการครบทั้ง 5 ขั้นตอนนี้ ตารางข้อมูลของคุณจะมีความสะอาด แม่นยำ และมีโครงสร้างที่สมบูรณ์แบบ 100% พร้อมสำหรับการนำไปเขียน Prompt สั่งการ AI (Gemini) ให้ช่วยวิเคราะห์กลยุทธ์ธุรกิจในสัปดาห์หน้า

Quizizz Arena: ประลองความรู้ Data Cleaning Master

 10 QUESTIONS

ทดสอบความเข้าใจ 10 ข้อ ก่อนลงมือปฏิบัติการจริงใน Workshop



สแกน QR Code หรือเข้าเว็บ

joinmyquiz.com

รหัสห้อง: แจ้งหน้าจอ

กฎการแข่งขัน

- คำถามทั้งหมด **10 ข้อ** (แบบ 3 ตัวเลือก A, B, C)
- เวลาตอบข้อละ **60 วินาที** ยิ่งตอบเร็วและถูก คะแนนยิ่งสูง
- คะแนนสะสม **20% ของวิชา**
- **Top 3 ของห้อง** รับ Badge พิเศษ "Data Cleaning Champion"



ให้อาจารย์กดเปิดเกมในระบบ Quizizz และจับเวลาพร้อมกันทั้งห้องเรียน (ใช้เวลาประมาณ 15 นาที)

🚩 สรุปบทเรียนประจำคาบ & Preview คาบหน้า

▶▶ NEXT STEP

บทวน 4 เสาหลัก และก้าวต่อไปสู่วงจรขั้นที่ 4 'ANALYZE' ด้วย AI

📌 สรุป 4 เสาหลักที่เราเรียนรู้วันนี้

- **1. Reality of Dirty Data:** ข้อมูลจริงมีมลพิษเสมอ กฎ 80/20 ในการเตรียมข้อมูล
- **2. 5 Traps:** จับทาง Duplicate, Whitespace, Missing, Format, และ Outliers
- **3. Google Sheets Toolkit:** TRIM, Remove Duplicates, Find/Replace, Validation
- **4. Audit Trail:** กฎ Don't Touch Raw Data และการเขียน Data Cleaning Log

🔗 สัปดาห์หน้า: Session 6 — ขั้นที่ 4 'ANALYZE'

ก้าวเข้าสู่ ขั้นที่ 4 'ANALYZE' (ส่วนที่ 1):

Prompt Engineering สำหรับวิเคราะห์ข้อมูลธุรกิจด้วย **Gemini:** นำข้อมูลสะอาดที่คลีนเสร็จในวันนี้ ไปอัปโหลดให้ AI ค้นหา Insight ยอดขายและคิดโปรโมชันอัตโนมัติ!

🔔 เตรียมตัวเข้าสู่ช่วงปฏิบัติการ Workshop: ลงมือคลีนชุดข้อมูลจริงพร้อมกัน



Workshop: "Data Cleaning Master ปฏิบัติการกู้วิกฤตข้อมูล SME"

 WORKSHOP 65 MINS

สวมบทบาท Data Consultant ประจำร้าน Chaba Clothing ทำความสะอาดข้อมูลจริง 5 ภารกิจ

📋 5 ภารกิจกู้วิกฤตข้อมูล (40 นาที)

- **Mission 1:** Duplicate Raw Data → สร้างชุด cleaned_data สำรองข้อมูลดิบ
- **Mission 2:** ลบแถวซ้ำ (Remove Duplicates) เช็ตาม Order ID
- **Mission 3:** ล้างช่องว่างแฝงด้วย Trim Whitespace และฟังก์ชัน TRIM()
- **Mission 4:** จัดระเบียบตัวสะกดสี/ไซส์ด้วย Find & Replace และ UPPER()
- **Mission 5:** จัดการ Missing Values, ตรวจจับ Outlier และเขียน Data Cleaning Log

👥 5 บทบาทสมาชิกในกลุ่ม

1. **Project Lead:** คำนวณเวลาและตรวจสอบความถูกต้องภาพรวม
2. **Sheet Master:** เป็นคนลงมือใช้เครื่องมือและคีย์สูตรใน Google Sheets
3. **Data Auditor:** ตรวจจับช่องว่าง ข้อมูลซ้ำ และ Outlier
4. **Log Keeper:** บันทึกทุกขั้นตอนลงใน Data Cleaning Log
5. **Presenter:** นำเสนอผลการคลีนและ Insight หน้าห้อง (3 นาที)



เปิดใบงาน: ให้นักศึกษาเปิดไฟล์ session-05-workshop-worksheet.html เพื่อรับลิงก์ไฟล์ Google Sheets และเริ่มลงมือทำได้เลย!